

所建立的機率矩陣藉由統計指標量化填回該移動視窗的中心，即可形成紋理影像，如圖 3-8 所示。




圖 3-8 統計指標量化產生紋理影像

由於前面的介紹為動態的移動視窗求取影像的局部灰階共生矩陣，其計算耗時且運算量較大，因此我們先將影像像素值映射到灰度級別 0~7 之間，即決定了灰階矩陣的大小固定為  $8 \times 8$ ，且設定移動視窗同為影像大小。在這樣的條件下直接計算整張影像的灰階共生矩陣，並統計量化使用公式(3.7)~(3.14)式求出八種特徵值。如圖 3-2(b)所示，本研究使用像素對的距離  $d=1$ ，每張影像中其像素對針對四種不同的相對方向分別統計，故共取得 32 種特徵值。

### 3.2.3 灰階連續長度矩陣(Gray Level Run-Length Matrix)之紋理特徵

灰階連續長度矩陣是在 1974 年由 Galloway [41]所提出的，其計算方式與灰階共生矩陣類似。其目的在於統計影像中各個灰階值在不同的方向上連續出現的最高次數，並定義了一些統計方法量化灰階連續長度矩陣中所包含的資訊。通常粗糙的紋理中，會有較長的灰階值連續長度，而平滑的紋理，會有較短的灰階值連續長度。於醫學影像處理上常結合此方法進行影像分類(Image classification)[39, 42]。

### 3.2.3.1 灰階連續長度矩陣的建立

二維的灰階連續長度矩陣建立流程如下:

- (1) 假設有 $5 \times 5$ 大小的原始影像，其灰階範圍為 2 位元，灰階值介於 0~3，如圖 3-9。

1	3	2	1	3
2	3	0	1	0
0	0	0	2	1
2	2	1	1	1
0	2	3	1	1

圖 3-9 原始影像

- (2) 建立空白的連續長度矩陣(Run-length matrix)，令  $L$  為灰階值總數， $R$  為在給定的方向上灰階值能夠連續的最大長度值，則其大小為  $L \times R$ 。而常用的方向  $\theta$  與共生矩陣同為  $0^\circ$ 、 $45^\circ$ 、 $90^\circ$  和  $135^\circ$ 。本例中，水平角等於  $0^\circ$  的連續矩陣大小為  $4 \times 5$ ，如圖 3-10。

		j				
		1	2	3	4	5
i	0					
	1					
	2					
	3					

圖 3-10  $\theta = 0^\circ$  之空白連續長度矩陣

- (3) 統計灰階值在影像中連續長度分布的情況， $p(i, j)$  為連續長度矩陣第  $(i, j)$  個元素的值，其中  $i$  代表灰階值， $j$  代表連續長度，表示灰階值  $i$  在給定的方向上連續長度為  $j$  的次數，而本例中水平角等於  $0^\circ$  所建立出的灰階連續長度矩陣如下圖 3-11。




圖 3-11 建立  $\theta = 0^\circ$  之灰階連續長度矩陣

原始影像中對應空白灰階連續長度矩陣中位置  $i = 0, j = 3$  時，出現次數為 1 次。

### 3.2.3.2 統計指標量化

在建立出灰階連續長度矩陣後，使用不同的統計方法來計算出統計特徵，我們採用原始灰階連續長度矩陣文獻[41]所提出的統計特徵以及其他幾種常見的紋理特徵[43]，分別為：

#### (1) Short Run Emphasis (SRE)

$$\text{SRE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R \frac{p(i, j)}{j^2} \quad (3.15)$$

其中  $n_r$  為連續長度的出現次數加總：

$$n_r = \sum_{i=1}^L \sum_{j=1}^R p(i, j) \quad (3.16)$$

(2) Long Run Emphasis (LRE)

$$\text{LRE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R p(i, j) \cdot j^2 \quad (3.17)$$

(3) Gray-Level Nonuniformity (GLN)

$$\text{GLN} = \frac{1}{n_r} \sum_{i=1}^L \left( \sum_{j=1}^R p(i, j) \right)^2 \quad (3.18)$$

(4) Run Length Nonuniformity (RLN)

$$\text{RLN} = \frac{1}{n_r} \sum_{j=1}^R \left( \sum_{i=1}^L p(i, j) \right)^2 \quad (3.19)$$

(5) Run Percentage(RP)

$$\text{RP} = \frac{n_r}{n_p} \quad (3.20)$$

其中  $n_p$  為像素點的數量， $n_p = L \times R$ 。

(6) Low Gray-Level Run Emphasis (LGRE)

$$\text{LGRE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R \frac{p(i, j)}{i^2} \quad (3.21)$$

(7) High Gray-Level Run Emphasis (HGRE)

$$\text{HGRE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R p(i, j) \cdot i^2 \quad (3.22)$$

(8) Short Run Low Gray-Level Emphasis (SRLGE)

$$\text{SRLGE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R \frac{p(i, j)}{i^2 \cdot j^2} \quad (3.23)$$

(9) Short Run High Gray-Level Emphasis (SRHGE)

$$\text{SRHGE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R \frac{p(i, j) \cdot i^2}{j^2} \quad (3.24)$$

(10) Long Run Low Gray-Level Emphasis (LRLGE)

$$\text{LRLGE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R \frac{p(i, j) \cdot j^2}{i^2} \quad (3.25)$$

(11) Long Run High Gray-Level Emphasis (LRHGE)

$$\text{LRHGE} = \frac{1}{n_r} \sum_{i=1}^L \sum_{j=1}^R p(i, j) \cdot i^2 \cdot j^2 \quad (3.26)$$

如圖 3-2(c)所示，我們將影像像素值映射到灰度級別 0~7 之間後計算整張影像的灰階連續長度矩陣，並統計量化使用公式(3.15)~(3.26)式求出 11 種特徵值。本研究在每張影像中針對四種不同的相對方向分別統計，故共取得 44 種特徵值。

### 3.2.4 田村紋理特徵(Tamura Texture Feature)

田村紋理特徵是根據人類的視覺感知系統所計算出的紋理特徵，由田村等人在 1987 年提出[44]，目前多應用於圖像檢索(Image retrieval)[45]。此種方法包含了六種特徵，本研究採用了其中三種與人類感知較有緊密關聯的特徵[45, 46]，分別為：

(1) 粗糙度(Coarseness, CRS)

粗糙度是田村紋理特徵中最基本的一個特徵，主要用於測量粗糙與細緻紋理的差異，其值越大表示紋理越粗糙，因此細緻的紋理的值會比粗糙紋理的小。其計算步驟如下：

步驟一：計算大小為  $2^k \times 2^k$  區域內所有像素點的平均強度值， $k \in (0, \dots, 5)$ ，如(3.27)式：

$$A_k(x, y) = \frac{1}{2^{2k}} \sum_{i=x-2^{k-1}}^{x+2^{k-1}-1} \sum_{j=y-2^{k-1}}^{y+2^{k-1}-1} I(i, j) \quad (3.27)$$

其中  $I(i, j)$  表示座標  $(i, j)$  的灰階值。

步驟二：對於每個像素點  $(x, y)$ ，分別計算水平(Horizontal)及垂直(Vertical)方向上不重疊區域之間的差值，如公式(3.28a)及(3.28b)：

$$\text{水平: } E_{k,h}(x, y) = \left| A_k(x + 2^{k-1}, y) - A_k(x - 2^{k-1}, y) \right| \quad (3.28a)$$

$$\text{垂直: } E_{k,v}(x, y) = \left| A_k(x, y + 2^{k-1}) - A_k(x, y - 2^{k-1}) \right| \quad (3.28b)$$

步驟三：在每個像素點上，選出一個最佳大小，如(3.29)式：

$$S_{best}(x, y) = 2^K \quad (3.29)$$

其中  $K$  為一個能令下式最大化的值：

$$E_K(x, y) = \max_k \left( E_{k,h}(x, y), E_{k,v}(x, y) \right), k = 0, 1, \dots, 5 \quad (3.30)$$

步驟四：計算圖像上  $S_{best}$  之平均值，即可計算出粗糙度，如(3.31)式：

$$F_{crs} = \frac{1}{M \times N} \sum_{i=1}^M \sum_{j=1}^N S_{best}(i, j) \quad (3.31)$$

其中  $M$  為影像的長度， $N$  為影像的寬度。

## (2) 對比度(Contrast, CON)

對比度特徵反映出影像中灰階值強度的分布情況，其大小由以下四個因素決定：灰階動態範圍(Gray-level dynamic range)、直方圖(Histogram)中黑白兩部分兩極化的程度、邊緣的銳利度(Sharpness)以及重複模式的週期。其計算公式如下：

$$F_{con} = \frac{\sigma}{(\alpha_4)^n} \quad (3.32)$$

其中  $\sigma$  為灰階分布的標準差(Standard deviation)， $n$  為一正數， $\alpha_4$  為平均值之四次矩(Forth moment)除以變異數的平方所得到的峰度(Kurtosis)，如(3.33)式：

$$\alpha_4 = \frac{\mu_4}{\sigma^4} = \frac{\sum_{i=1}^M \sum_{j=1}^N (f(i, j) - \mu)^4}{M \times N \times \sigma^4} \quad (3.33)$$

其中  $\mu$  為平均值。經過實驗，田村等人發現當(3.32)式之  $n=1/4$  時與人類的測量最接近一致。

## (3) 方向性(Directionality, DIR)

方向性特徵包含了影像中的全域特性，用來描述紋理是如何沿著特定方向分散或者集中。若兩張影像的差異只有在方向上，則此特徵值會相同。其計算步驟如下：

步驟一：計算每個像素點的梯度向量(Gradient vector)包括其大小 $|\Delta G|$ 及方向 $\theta$ ，如下所示：

$$|\Delta G| = \frac{|\Delta_H| + |\Delta_V|}{2} \quad (3.34)$$

$$\theta = \tan^{-1} \left( \frac{\Delta_V}{\Delta_H} \right) + \frac{\pi}{2} \quad (3.35)$$

其中 $\Delta_H$ 及 $\Delta_V$ 分別為水平及垂直方向上的變化量，由影像分別與下列兩個 $3 \times 3$ 運算子作迴旋積運算後所得到。而所得到的 $\theta$ 為一個由逆時針方向測量的實數，因此水平方向為零。

$$\text{水平:} \quad \begin{vmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{vmatrix} \quad (3.36a)$$

$$\text{垂直:} \quad \begin{vmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{vmatrix} \quad (3.36b)$$

步驟二：建構邊緣機率直方圖(Edge probability histogram) $H_D$ 來量化 $\theta$ ，並且計算所有 $|\Delta G|$ 大小超過閾值 $t$ 的點如(3.37)式：

$$H_D(k) = \frac{N_\theta(k)}{\sum_{i=0}^{d-1} N_\theta(i)}, k = 0, 1, \dots, d-1 \quad (3.37)$$

其中 $N_\theta(k)$ 為所有滿足 $(2k-1)\pi/2d \leq \theta \leq (2k+1)\pi/2d$ 及 $|\Delta G| \geq t$ 的點。利用閾值 $t$ 來限定 $|\Delta G|$ 是為了防止去計算非邊緣點造成的不可靠方向。

步驟三：最後，方向性可透過計算直方圖中峰值(Peak)的銳度(Sharpness)來獲得，如(3.38)式：



$$F_{dir} = 1 - r \times n_p \times \sum_p^{n_p} \sum_{\phi \in w_p} (\phi - \phi_p)^2 H_D(\phi) \quad (3.38)$$

其中  $n_p$  為峰的數量， $\phi_p$  為在  $H_D$  中第  $p$  個峰的中心位置， $w_p$  為第  $p$  個峰的範圍， $r$  為一正規化因子，與量化  $\phi$  的程度有關，而  $\phi$  為量化方向的規則(週期性的  $180^\circ$  取模)。

### 3.3 特徵選取

隨著影像技術的快速發展，影像中可以獲得的資訊也越來越多，即使是單色調的磁振影像，仍可利用許多影像處理的技術，從影像中取得許多特徵資訊。由 3.2 節所介紹的特徵擷取方法，所擷取的全部特徵資訊雖然可以對影像內容做更詳細的描述，但當計算的資料維度過大時，容易造成資料分析上的困難。而特徵選取便是一種能根據特徵資訊的重要性加以篩選的技術，於特徵集合中，刪除對分類辨識能力較低的特徵，僅保留有助於分類辨識的重要特徵子集合，以便更有效地和機器學習(Machine learning)與圖形辨識(Pattern recognition)結合[47, 48]。此技術之目的在於縮減特徵資料維度，降低運算處理上的複雜度及時間，進而提升效率及辨識率。

本研究先使用 t 檢定[34, 35]作為特徵選取法則，判斷各特徵變數能否明顯分辨摻有不同雜訊之磁振影像，並依照各特徵的分辨能力初步篩選出具有高鑑別度的特徵，作為候選特徵子集合。最後使用循序前進浮動選取法[36]，從候選特徵子集合中挑選出最佳的特徵組合，以作為訓練類神經網路的輸入資料。

#### 3.3.1 T 檢定

T 檢定，亦稱學生 t 檢定(Student's t-test)[34, 35]，是一種以計算變數的平均值做為比較的方法，用於檢驗樣本的變數平均值差異程度，透過 t 分佈理論來推斷差異發生的概率，進而判定變數是否有顯著差異的特性。依比較的樣本數可分為單樣本 t 檢定(One sample t-test)和雙樣本 t 檢定(Two samples t-test)，其中單樣本 t 檢定是用來比較一組樣本數據之平均值與一特定值有無差異，而雙樣本 t 檢定則是以